

Année Universitaire : 2024/2025 Master 2 : SII Module : Recherche d'Information	Université des Sciences et de la Technologie Houari Boumediene Faculté d'Informatique Département d'Intelligence Artificielle et Sciences des Données	TP N°5 Recherche de l'Information : Appariement Partie 2
---	---	---

Support :

1. Extraction de termes (Tokens) à l'aide de l'expression régulière suivante :

```
nlTK.RegexpTokenizer('(?:[A-Za-z]\. )+|[A-Za-z]+[\-@]\d+(?:\.\d+)?|\d+[A-Za-z]+|\d+(?:[\.\,\-]\d+)?%?|\w+(?:[\-/\]\w+)*')
```

2. Appariement :

2.1. Modèle Probabiliste

2.1.1. Modèle BM25

Entrée (requête) :

Un ensemble de termes normalisés

Sortie :

Une liste de documents ordonnés selon leurs degrés de pertinences. Le degré de pertinence *RSV* d'un document *d* par rapport à une requête *Q* est calculé à l'aide de la méthode probabiliste **BM25** comme suit :

$$RSV(Q, d) = \sum_{i \in Q} \left(\frac{freq(t_i, d)}{K \left((1 - B) + B * \frac{dl}{avdl} \right) + freq(t_i, d)} \right) * \left(\log \left(\frac{N - n_i + 0.5}{n_i + 0.5} \right) \right)$$

Avec :

freq(t_i, d) : la fréquence du terme *i* dans le document *d*.

dl : la taille du document *d* (nombre de termes). La taille est calculée sur la base des fréquences des termes.

avdl : la taille moyenne des documents (nombre de termes).

K & *B*, sont des constantes.

N : le nombre de documents dans la collection.

n_i : le nombre de documents contenant le terme *i*.

log : c'est le Log de 10.

Exercice :

I. Implémenter la méthode probabiliste BM25.

II. Visualiser les résultats retournés de la méthode probabiliste BM25.

Introduire la requête

RI Project 2024

Query Information retrieval LLMs **Search** ☐ Queries Dataset 1

Processing Token RegEx Stemmer Porter

Index ☐ DOCS per TERM ☒ TERMS per DOC

Matching ☐ Vector Space Model ☒ Probabilistic Model (BM25)

Scalar Product

K 1.50

B 0.75

Content

which is based on the blackbox commercial GPT-4 that has 50x (estimated) model size, while outperforming other LLM-based solutions, such as InstructGPT which has 175B parameters, by over 12-10% for all ranking metrics. By using the same prompt template on seven BEIR tasks, PRP outperforms supervised baselines and outperforms the blackbox commercial ChatGPT solution by 4.2% and pointwise LLM-based solutions by more than 10% on average NDCG@10. Furthermore, we propose several variants of PRP to improve efficiency and show that it is possible to achieve competitive results even with linear complexity

Find

Results

N°doc	Relevance
1	0.1090
4	-0.3260
2	-0.4062
3	-0.4215
6	-0.5229
5	-0.6055

Résultats retournés par le
modèle probabiliste BM25